do zdobycia: [20pkt] czas realizacji: 2 tygodnie

## Zestaw 2

Tym razem zajmiemy się już nieco bardziej złożonym problemem. Zadaniem jest napisanie programu równoległego służącego do (niezbyt złożonego) przetwarzania wektorów.

Problem można sformułować w sposób następujący:

- 1. dane jest N wektorów z przestrzeni  $\mathbb{R}^3$ , wektory te oznaczmy jako  $\mathbf{r}_i = [x_i, y_i, z_i]$ , oczywiście  $i = 1, 2, \dots, N$ ,
- 2. należy obliczyć średnią długość l oraz średni wektor  $\langle \mathbf{r} \rangle$ , dane są one wzorami

$$l = \frac{1}{N} \sum_{i=1}^{N} |\mathbf{r}_i| = \frac{1}{N} \sum_{i=1}^{N} \sqrt{x_i^2 + y_i^2 + z_i^2}$$
 (1)

oraz

$$\langle \mathbf{r} \rangle = \left[ \langle x \rangle, \langle y \rangle, \langle z \rangle \right], \tag{2}$$

gdzie

$$\langle q \rangle = \frac{1}{N} \sum_{i=1}^{N} q_i \tag{3}$$

oraz  $q = \{x, y, z\}.$ 

Poniżej (w punktach) przedstawiona została specyfikacja programu, który należy napisać. W ramach kolejnego ćwiczenia program ten zostanie rozwinięty (ulepszony). Warto więc od samego początku zadbać, by jego kod był przemyślany i przejrzysty.

1. Na wstępie program powinien wczytać dane (współrzędne wektorów) z pliku (tekstowego). Załóżmy, że plik z danymi posiada następujący format (symbolicznie):

Jak widać, w *i*-tej linii pliku określone są składowe wektora  $\mathbf{r}_i$ . Na wstępie przyjmiemy dość proste podejście, w którym **każdy** z procesów będzie wczytywał **całość** danych z pliku. Należy przyjąć, że przy uruchomieniu programu **nie jest** znana ilość danych w pliku (tj. liczba wektorów N). Program powinien ustalić wartość N w trakcie czytania pliku z danymi. Dla uproszczenia można jednak przyjąć, że  $1 \leq N \leq 10^6$ .

UWAGA: do czytania danych z pliku **nie stosujemy** (póki co...) mechanizmów dostarczanych przez MPI.

2. W etapie następnym powinna nastąpić dekompozycja problemu. Dane wejściowe należy podzielić na n bloków, o – w miarę możliwości – równych rozmiarach. W zależności od wartości n (liczba procesów) oraz wartości N (liczba wektorów), program powinien ustalić wartości  $i_k^0$  oraz  $i_k^1$ . Symbole  $i_k^0$  oraz  $i_k^1$  oznaczają indeksy pierwszego oraz ostatniego wektora, o które "troszczy się" proces k-ty ( $k = 0, 1, \ldots, n-1$ ). Oczywiście, proces k-ty

powinien troszczyć się o wszystkie wektory o indeksach z zakresu od  $i_k^0$  (włącznie) do  $i_k^1$  (włącznie). Koniecznie należy zadbać, by nakład pracy był równomiernie rozdzielany pomiędzy procesy. Koniecznie należy też zadbać, by program działał prawidłowo w przypadkach, w których N nie jest całkowitą wielokrotnością n. Program powinien również działać prawidłowo w sytuacjach, w których N < n. Warto solidnie zastanowić się nad algorytmem wyznaczania  $i_k^0$  oraz  $i_k^1$ . Warto również uprościć ten algorytm.

UWAGA: rozważany problem zawsze można zdekomponować tak, że dowolne dwa procesy "dostają" porcje różniące się o nie więcej aniżeli jeden wektor.

WSKAZÓWKA: co wyrażają wartości N / n oraz N % n?

- 3. W kroku kolejnym każdy z procesów oblicza swój wkład do sum pojawiających się w (1) oraz (3).
- 4. W etapie następnym redukowane są rezultaty częściowe (obliczone przez poszczególne procesy składowe sum (1) oraz (3)). Zrealizować to należy wykorzystując funkcję MPI\_Reduce.
- 5. W ostatnim kroku master oblicza wartość l oraz  $\langle \mathbf{r} \rangle$ , wypisując rezultaty na ekranie.

Dodatkowo program powinien mierzyć czasy wykonania poszczególnych etapów obliczeń. Do pomiarów czasów należy posłużyć się funkcją MPI\_Wtime. Program wyszczególniać powinien czasy niezbędne do realizacji poszczególnych etapów, w tym: czas potrzebny na wczytanie danych, czas potrzebny na obliczenie wkładów do średnich, czas potrzebny na redukcję wyników. Po zakończeniu obliczeń program powinien zapisać informację o czasach wykonania do pliku tekstowego. Jego postać może wyglądać następująco:

## timings (proc 0):

readData: 1.24351 processData: 0.00634193 reduceResults: 0.000319004 total: 1.25017

timings (proc 1):

readData: 1.24423 processData: 0.00612283 reduceResults: 0.00022006 total: 1.25057

timings (proc 2):

total timings:

readData: 3.31604 processData: 0.0185068 reduceResults: 0.000674248 total: 3.33522 Plik ten powinien być tworzony przez mastera. Do wymiany informacji o czasach wykonania pomocna może okazać się funkcja MPI\_Gather.

Przykładowe dane wejściowe znaleźć można na olimpie w katalogu "swinczew/AR. W katalogu tym znajdują się pliki o nazwach v01.dat, v02.dat, ..., v06.dat. W katalogu tym znajduje się również plik o nazwie vresults.dat. Zawiera on prawidłowe wyniki (obliczone dla poszczególnych plików wejściowych wartości l oraz  $\langle \mathbf{r} \rangle$ ). Warto upewnić się, że program zwraca identyczne rezultaty. Warto również upewnić się, że zwracane przez program rezultaty nie zależą od n (liczby procesów). Dane testowe można także pobrać spod adresu:

## http://www.mif.pg.gda.pl/homepages/swinczew/AR/data

## Kryteria oceniania:

- 1. rozsądna, prawidłowa i zgrabna metoda dekompozycji danych [4pkt],
- 2. prawidłowa implementacja części obliczeniowej [4pkt],
- 3. prawidłowy i zgrabny schemat komunikacji [4pkt],
- 4. implementacja funkcjonalności pomiaru czasów wykonania, analiza i omówienie czasów wykonania [4pkt],
- 5. estetyka i struktura kodu [4pkt].